Documentație Calcul numeric

Gherghe Ana-Alexandra
Matei Thea Sorana
Sebacher Maria-Alexandra

Mai 2026

1 Introducere

Inteligența artificială a devenit un instrument omniprezent, utilizat la scară largă: de la studenții care încearcă să asimileze în sesiune materia întregului semestru, până la companii care o folosesc pentru creșterea productivității sau utilizatori care o explorează în scop recreativ și de divertisment.

Aproape fiecare dintre noi s-a regăsit măcar o dată în aceste ipostaze. Primele noastre interacțiuni cu IA au fost ghidate de curiozitate și divertisment, testându-i limitele prin solicitări precum: compunerea rimelor, idei creative sau generarea de imagini amuzante. Treptat, am început să ne dorim să înțelegem mecanismele din spatele acestui instrument.

O întrebare sugestivă de la care am pornit documentarea proiectului nostru este următoarea: Cum a învățat, însă, IA să reproducă sarcini pe care oamenii le perfecționează de mii de ani?

Un domeniu care până de curând necesita autenticitate, sensibilitate și inspirație a devenit azi un instrument de marketing și promovare. Bannerele stradale, afișele publicitare, postările de pe rețelele de socializare și reclamele adoptă treptat imagini, efecte și videoclipuri generate de IA. Totuși, IA are un stil specific, caracteristic. Acest lucru se datorează modului de funcționare: algoritmul primește ca date de intrare mii de matrici informaționale pe care le analizează, învățând" tipare din ele pentru a genera ulterior structuri noi cu aceleași proprietăți.

Această tranziție rapidă către digitalizare este susținută și de datele statistice oficiale. Conform unui raport Eurostat, utilizarea inteligenței artificiale generative a cunoscut o creștere accelerată în rândul tinerilor din Europa, media europeană de adoptare în rândul populației cu vârste între 16 și 24 de ani ajungând la 63,8%.

În acest context, apare întrebarea: de ce un prompt mai contextualizat oferă un rezultat mult mai apropiat de nevoile noastre? Răspunsul stă într-un principiu fundamental al informaticii: calitatea datelor de intrare (input) este direct proporțională cu calitatea rezultatului generat (output).

Inteligenta artificiala are urmari atat pe plan micro, influentand productivitatea, ideile si chiar starea de spirit a unei persoane, dar si la nivel macro, pe plan socio-economic devenind principalul factor al concedierilor in masa, principalele posturi afectate avand chiar ca task principal generarea de continut: Ilustratori, Traducători, Copywriterii, Agenți de suport clienți Inteligenta artificiala a revolutionat complet domenii precum educatia primara si prescolara, scurtând timpul de executie al materialelor didactice si al planurilor de lectie exponetial; in consultare de tip juridic, verificarea codului penal fiind mult mai rapida folosind acest instrument, sau chiar in domeniul antreprenorial. Proiectul nostru isi propune sa studieze ingineria din spatele generarii de imagine ce sta la baza acestei inteligențe artificiale, o tehnologie atat de actuala si de importanta fundamentala in crearea joburilor, economiei si societății de maine.

2 Aplicația aleasă

În contextul actual, cunoașterea modalității de funcționare a inteligențelor artificiale a format actuala aplicație. Aceasta se numește "Generarea de imagini dintr-un set de imagini ce au aceeasi distribuție Gaussiana". Pe baza proprietăților imaginilor din set, reușim să creem cu totul alte imagini, dar care să păstreze proprietățile setului initial.

3 Descrierea matematică a metodei folosite

Imaginile de bază (din setul de antrenare) sunt formate cu datele din fișierul text E.txt. În fișier se află o matrice E cu 10000 de linii și 1000 de coloane. Fiecare coloană este un vector 10000-dimensional care, transformat într-o matrice de 100**x**100, reprezintă o simulare a unui câmp Gaussian de medie 0 și matrice de covarianță C. Matricea de covarianță oferă informații legate de corelația spațială a valorilor câmpului Gaussian. In cazul exemplului aratat, matricea de covarianta folosita urmeaza un model spatial Gaussian:

$$c(h) = e^{-h^2/r^2}. \tag{1}$$

De asemenea câmpul Gaussian are următoarele proprietăți geostatistice- o anisotropie cu o lungime principală de corelație de 70 de celule, o lungime secundară de 10 celule si un unghi de 120°.

In Figura 1 prezentăm primele 6 imagini din setul de antrenare - ele reprezinta 6 câmpuri Gaussiene cu proprietățile geostatistice prezentate anterior. Nu vom folosi aceste informații despre forma matricii de covarianță în studiul nostru. Vom folosi exclusiv setul de date. Cu toate acestea vom prezenta câteva informații despre aceasta:

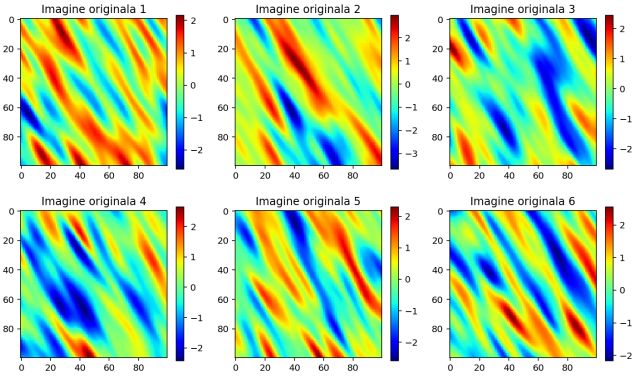


Figure 1: Exemplu de campuri Gaussiene

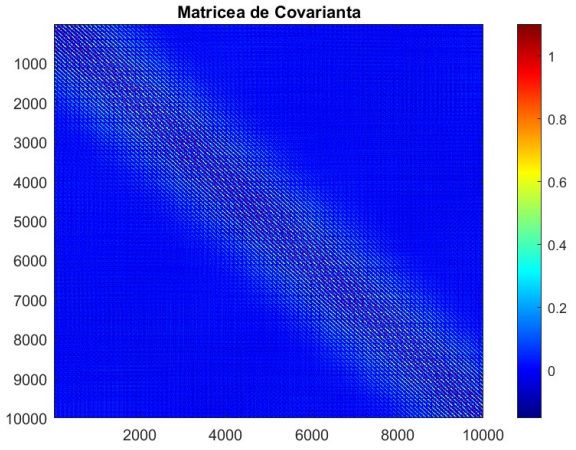


Figure 2: Matricea de Covarianta

- C este o matrice pătratică, simetrică și cu toate valorile proprii mai mari ca 0 (i.e. pozitiv definită). În cazul exemplului nostru, forma ei este prezentată in Figura 2.
- Dacă matricea C este matricea de identitate, distribuția noastră Gaussiană va purta numele de "zgomot" (noise). În partea dreaptă a figurii 3 prezentăm histograma tuturor valorilor din imagine. Se observă proprietatea distribuției Gaussiene care concentrează numerele în jurul valorii 0 și creează o formă care poartă denumirea de "Clopot Gaussian". Dispersia valorilor este, in cazul prezentat 1. Aceasta face ca distribuția sa se numească standard Gaussiană.

Cum noi folosim exclusiv imaginile din setul de antrenare, nu vom presupune

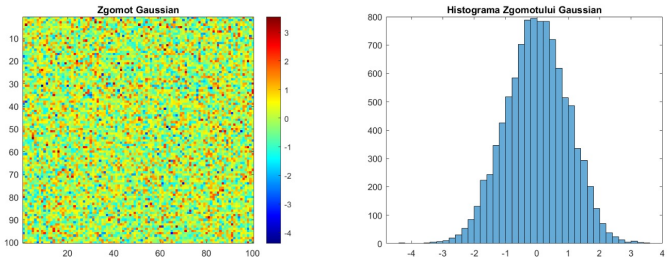


Figure 3: Zgomot Gaussian

ca știm care este matricea de covarianță. De aceea o vom aproxima din cele 1000 de imagini(campuri) din setul de antrenare. Aceasta presupune realizarea următorilor pași:

1. Se calculeaza media valorilor imaginilor

$$m = \frac{1}{N} \cdot \sum_{i=1}^{N} E_i$$

2. Se calculeaza matricea $A = E - m$

$$A = \left[\; E_1 - m \; \middle| \; E_2 - m \; \middle| \; \dots \; \middle| \; E_n - m \; \right]$$

   Media matricei A va fi: $\bar{A} = 0$

3. Se aproximeaza matricea de covarianță C:

$$C = \frac{1}{N-1} \cdot A \cdot A^t$$

Vom presupne ca datele noastre $E_1, E_2, \dots, E_N$ sunt simulate dintr-o distribuție Gaussiană de medie 0 și matricea de covarianță C.

Pentru a simula alte imagini/câmpuri ne vom folosi de urmatoarea ecuație :

$$X = m + \sqrt{C} \cdot \xi \tag{2}$$

In aceasta ecuatie ξ urmeaza o distribuție gaussiană N(0; I) (este un zgomot Gaussian). Pentru a putea folosi ecuația trebuie să definim ce inseamnă $\sqrt{C}$ din perspectiva simularii. Pentru aceasta vom folosi diagonalizarea matricii de covarianță. Vom face diagonalizarea prin factorizarea SVD a matricii A. Descompunem matricea A prin metoda SVD:

$$A = U \cdot \Sigma \cdot V^T \tag{3}$$

- Σ are dimensiunea de 10.000 X 1000
- U are dimensiunea 10.000 X 10.000
- V are dimensiunea 1.000 X 1.000

Vom scrie matricea C în felul următor:

$$
\begin{aligned}
C &= \frac{1}{N-1} U \cdot \Sigma \cdot \underbrace{V^T \cdot V}_{I} \cdot \Sigma^T U^T \\
C &= \frac{1}{N-1} U \cdot \Sigma \cdot \Sigma^T U^T \\
C &= \frac{1}{N-1} (U \cdot \Sigma)(U \cdot \Sigma)^T \\
C &= \underbrace{\left(\frac{1}{\sqrt{N-1}} U \cdot \Sigma \right)}_{\sqrt{C}} \cdot \left(\frac{1}{\sqrt{N-1}} U \cdot \Sigma \right)^T
\end{aligned}
\tag{4}
$$

Definim în scopul simulării $\sqrt{C} = \frac{1}{\sqrt{N-1}} U \cdot \Sigma$ Astfel putem scrie noile noastre imagini/câmpuri astfel:

$$
X = m + \frac{1}{\sqrt{N-1}} \cdot U \cdot \Sigma \cdot \xi \tag{5}
$$

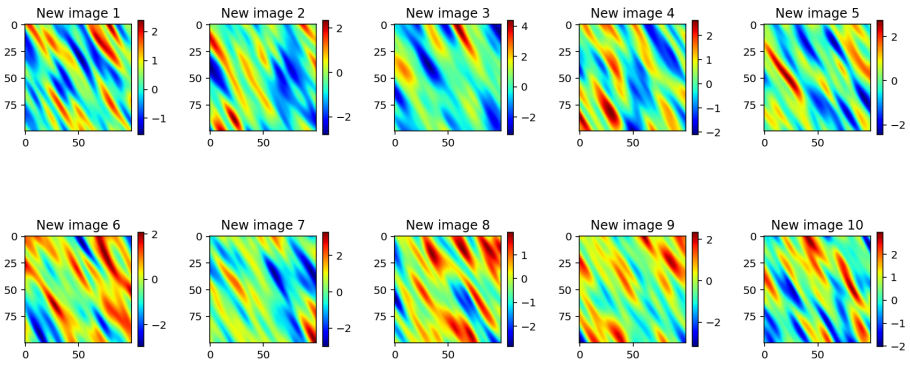


Figure 4: Imagini noi simulate

Figura 4 prezinta 10 noi imagini simulate din distributia Gaussiană definită de setul de antrenament folosit. Se observă că acestea păstrează aceleași proprietăți geostatistice (geometrice) ca și imaginile din setul de antrenare.
Considerații tehnice referitoare la ecuația:

$$
X = m + \sqrt{C} \cdot \xi \tag{6}
$$

unde
$\sqrt{C} = \frac{1}{\sqrt{N-1}} U \cdot \Sigma$ este o matrice 10000 X 1000, ξ este un vector 1000 - dimensional. În machine learning acest vector se numește encodare a câmpului X. În practică dimensiunea lui ξ este de fapt mai mică și ține de numărul de valori singulare semnificative ale factorizarii SVD. Figura 5 prezintă valorile singulare

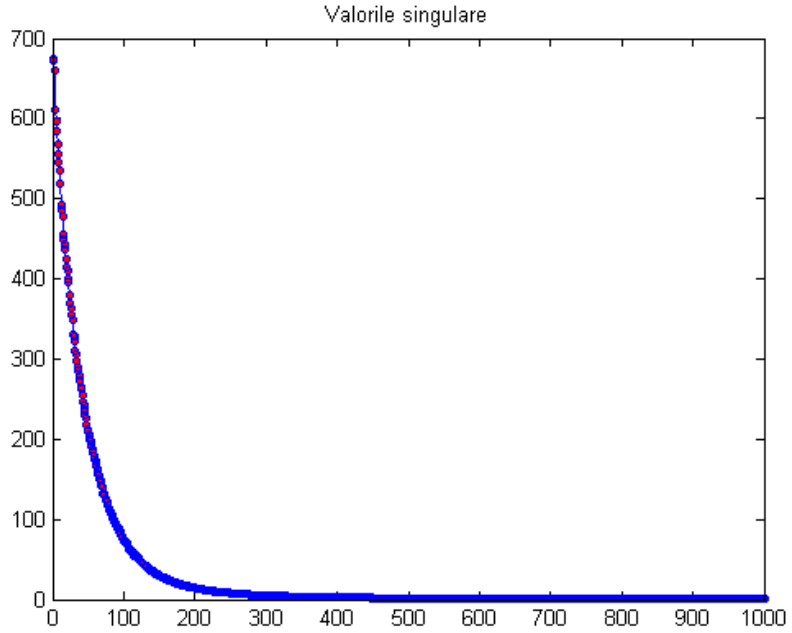


Figure 5: Valorile singulare

ale factorizarii SVD, în ordine descrescătoare. Se poate observa ca foarte multe sunt în vecinatătea lui zero. Aceasta înseamnă ca informația adusă de vectorii singulari este nesemnificativă. Se poate reduce astfel encodarea de la 1000 la 300, folosind primele 300 de valori singulare semnificative. Acest studiu trebuie făcut separat, însă.

4 Motivarea funcțiilor folosite în obținerea valorilor și vectorilor singulari

Am folosit iterația QR și tridiagonalizarea Householder pentru această aplicație pentru a îmbunătăți timpul de rulare al programului (exemplificat la curs cu $O(n^2)$ în loc de $O(n^3)$ și a genera valorile și vectorii proprii.

Utilitatea lor este în eficiență și stabilitate numerică, care optimizează obținerea

valorilor proprii și vectorilor proprii într-un algoritm din punct de vedere matematic inteligibil.

5 Utilitatea alegerii SVD

Din descompunerea matrici prin SVD, observăm ce ne influențează imaginile și cadrul alcătuirii lor cu alte valori, păstrând intact formatul. Informațiile generale ale imaginilor și proprietățile lor sunt păstrate ca rotiri și valori în spațiu, dar de asemenea și ca distribuție gaussiană a valorilor matricii.

6 Interpretarea rezultatelor

Programul rulează corect și generează 10 noi imagini cu aceleași proprietăți cu imaginile de antrenament. Avantajul programului SVD manual este flexibilitatea algoritmului, deoarece putem extrage variabile intermediare, modifica algoritmul, dar și hibridiza algoritmul după nevoie. Printre dezavantajele SVD-ului manual se numără durata rulării programului, care încetinește algoritmul și crearea imaginilor rapid, ca și precizia obținerii valorilor proprii și vectorilor proprii, erorile mari influențând rezultatele.